Business Intelligence
Tarea 4: Introducción a Series de Tiempo

Noel Eduardo Sánchez Useda

25 de octubre de 2026

Parte 0: Procesos simulados

0.1 Derivaciones a mano

Sea el AR(1) estacionario $Y_t = c + \phi Y_{t-1} + \varepsilon_t$, con $|\phi| < 1$ y $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$.

Media. Por estacionariedad, $E[Y_t] = E[Y_{t-1}] = \mu$. Tomando esperanza en ambos lados:

$$\mu = c + \phi\mu + 0 \implies \mu(1-\phi) = c \implies E[Y_t] = \frac{c}{1-\phi}.$$

Varianza. Como ε_t es independiente de Y_{t-1} y $\text{Var}(Y_t) = \text{Var}(Y_{t-1}) = \gamma_0$:

$$\gamma_0 = \phi^2\gamma_0 + \sigma^2 \implies \gamma_0(1-\phi^2) = \sigma^2 \implies \text{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}.$$

Se necesita $|\phi| < 1$ para que el denominador sea estrictamente positivo; si $\phi = 1$ la expresión no está definida y no existe una varianza estacionaria finita.

Autocorrelación. Como $c = \mu(1-\phi)$, el proceso centrado es $Y_t - \mu = \phi(Y_{t-1} - \mu) + \varepsilon_t$. Multiplicando por $(Y_{t-k} - \mu)$ con $k \geq 1$ y tomando esperanza:

$$\gamma_k = \phi\,\gamma_{k-1} + E[\varepsilon_t(Y_{t-k} - \mu)] = \phi\,\gamma_{k-1},$$

pues ε_t es independiente de todo el pasado. Aplicando la recursión k veces, $\gamma_k = \phi^k\gamma_0$, y por tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria ($\phi = 1$, $c = 0$, $Y_0 = 0$). Sustituyendo hacia atrás, $Y_t = \sum_{i=1}^{t} \varepsilon_i$, así que

$$\text{Var}(Y_t) = \sum_{i=1}^{t} \text{Var}(\varepsilon_i) = t\sigma^2.$$

La estacionariedad débil exige varianza constante en el tiempo. Aquí $\text{Var}(Y_1) = \sigma^2$, $\text{Var}(Y_2) = 2\sigma^2, \ldots$, es decir, crece linealmente con t, por lo que el proceso no es estacionario.

0.2 Simulación

Por qué se descartan los primeros 200 pasos. Para $|\phi| < 1$, la influencia del valor inicial decae como ϕ^t, de modo que al llegar a $t = 200$ el proceso ya olvidó Y_0 y su varianza se estabilizó en $\sigma^2/(1-\phi^2)$. Para $\phi = 1$ eso no ocurre: la memoria de Y_0 nunca decae y $\mathrm{Var}(Y_t) = t\sigma^2$ sigue creciendo, así que no existe un estado estacionario al cual converger.

Por qué el descarte no afecta a r_k cuando $\phi = 1$. Si se descartan los primeros 200 pasos, el tramo restante es $Y_t = Y_{200} + \sum_{i=201}^{t} \varepsilon_i$. La autocorrelación muestral r_k usa las desviaciones $y_t - \bar{y}$, y la constante Y_{200} se cancela al restar la media muestral. Lo que queda es una caminata aleatoria que parte de cero con incrementos iid, cuya distribución es la misma que la de la serie completa. Por eso el punto de partida no altera la distribución de r_k.

Resultados (5,000 réplicas por ϕ, $n = 300$). La Figura 1 muestra una realización por escenario y el Cuadro 1 resume las réplicas. Las semillas son `SEED_BASE`$+i$ para el escenario i, con `SEED_BASE`$=$ 2026 (las realizaciones de la figura usan `SEED_BASE`$+100+i$). El error estándar de cada promedio es la desviación estándar entre $\sqrt{5000}$; el de la tasa de rechazo p es $\sqrt{p(1-p)/5000}$.

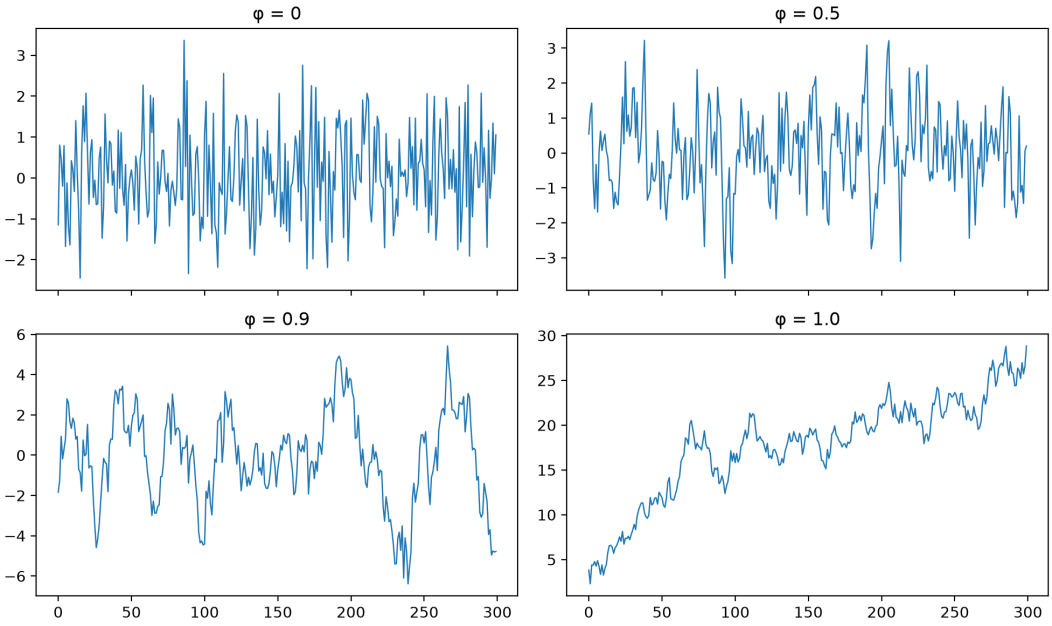


Figura 1: Una realización de 300 pasos por $\phi \in \{0, 0{,}5, 0{,}9, 1\}$. Con $\phi = 0$ la serie oscila rápidamente alrededor de 0 sin patrón visible (ruido blanco). Al aumentar ϕ los valores cercanos se parecen más y aparecen tramos largos del mismo lado de la media, más largos con $\phi = 0{,}9$. Con $\phi = 1$ la serie vaga a la deriva sin regresar a un nivel de equilibrio, lo que refleja $\mathrm{Var}(Y_t) = t\sigma^2$. La tendencia ascendente que se ve en esta realización es producto del azar, no una tendencia determinista.

ϕ	$\bar{r}_1$	e.e.	$\bar{r}_5$	e.e.	ϕ^5	rechazo r_1	e.e.	$\hat{\phi}_{OLS}$	e.e.
0.0	−0,0039	0.0008	−0,0028	0.0008	0.0000	0.0500	0.0031	−0,0039	0.0008
0.5	0.4892	0.0007	0.0199	0.0010	0.0312	1.0000	0.0000	0.4909	0.0007
0.9	0.8839	0.0004	0.5339	0.0014	0.5905	1.0000	0.0000	0.8871	0.0004
1.0	0.9758	0.0002	0.8835	0.0009	1.0000	1.0000	0.0000	0.9824	0.0002

Cuadro 1: Promedios sobre 5,000 réplicas con su error estándar, tasa de rechazo de la prueba $|r_1| > 1{,}96/\sqrt{n}$ y promedio del estimado OLS de ϕ.

0.3 Análisis

Tasa de rechazo con $\phi = 0$. Es 0,0500 (e.e. 0,0031), que es lo esperado. Con ruido blanco la hipótesis nula es cierta, y las bandas $\pm 1{,}96/\sqrt{n}$ corresponden a un nivel de significancia del 5 %. Como cada réplica produce un solo r_1, el 5 % de las *réplicas* cae fuera de las bandas por puro azar.

Caminata aleatoria. Para $\phi = 1$ la teoría da $\phi^5 = 1$, pero el promedio de r_5 es 0.8835: la autocorrelación muestral queda por debajo del valor teórico. La brecha respecto a ϕ^5 crece al acercarse ϕ a 1 (0.0113 para $\phi = 0{,}5$, 0.0566 para $\phi = 0{,}9$ y 0.1165 para $\phi = 1$), de modo que en muestras finitas r_k subestima ϕ^k, y más cuanto más persistente es la serie. Esto ocurre porque r_k resta la media muestral $\bar{y}$, estimada con los mismos datos: en una serie persistente $\bar{y}$ absorbe parte de la variación lenta, lo que reduce las desviaciones y sesga r_k hacia abajo. Además, el numerador suma $n - k$ términos mientras el denominador suma n, lo que también encoge r_k.

Sesgo del estimador OLS. El promedio de $\hat{\phi}$ queda siempre por debajo del ϕ verdadero y la diferencia mide varios errores estándar, por lo que no es ruido de simulación. El sesgo es −0,0039 para $\phi = 0$, −0,0091 para $\phi = 0{,}5$, −0,0129 para $\phi = 0{,}9$ y −0,0176 para $\phi = 1$: se agudiza al acercarse a la raíz unitaria. Es un sesgo de muestra finita, del orden de $1/n$, que se reduce al crecer n; por tanto el estimador OLS es consistente.

0.4 Las dos razones para reprobar

Proceso	$\bar{r}_1$	e.e.	rechazo r_1	e.e.	$\bar{r}_7$	e.e.
$\phi = 0$ (referencia)	−0,0039	0.0008	0.0500	0.0031	−0,0017	0.0008
(a) tendencia lineal	0.2446	0.0008	0.9834	0.0018	0.2297	0.0008
(b) patrón semanal	−0,0476	0.0007	0.1050	0.0043	0.2642	0.0008

Cuadro 2: Procesos sin memoria $Y_t = m_t + \varepsilon_t$ con 5,000 réplicas ($n = 300$). Semillas: `SEED_BASE`+0 para $\phi = 0$, `SEED_BASE`+10 para (a) y `SEED_BASE`+11 para (b).

(a) reprueba aunque no tiene memoria. Los errores son independientes, pero la media cambia con el tiempo: los primeros puntos quedan por debajo de $\bar{y}$ y los últimos por encima, de modo que las desviaciones vecinas comparten signo, lo que infla r_1 ($\bar{r}_1 = 0{,}2446$) y produce una tasa de rechazo de 98.34 %. Es la razón (2) de la tarea: la media no es constante. Por la misma razón $\bar{r}_7 = 0{,}2297$ también es positivo: la tendencia infla las autocorrelaciones en todos los rezagos.

(b) casi pasa aunque tiene estructura. La media del patrón es exactamente 0. Para la mayoría de los días consecutivos el producto es $0{,}25 \times 0{,}25$, un valor positivo pequeño, pero el día de $-1{,}5$ aparece una vez por semana y participa en dos productos (con el día anterior y el siguiente), cada uno de $-0{,}375$. Esos productos dominan la suma y empujan el valor esperado de r_1 hacia valores negativos ($\bar{r}_1 = -0{,}0476$), por lo que la tasa de rechazo es 10.5 %: por encima del 5 % de la referencia, pero muy por debajo de la de (a). La estructura aparece en el retardo 7, donde $\bar{r}_7 = 0{,}2642$. Es moderado y no cercano a 1 porque el ruido ($\sigma^2 = 1$) diluye la señal: el valor aproximado es $\mathrm{Var}(m)/(\mathrm{Var}(m) + \sigma^2) = 0{,}375/1{,}375 \approx 0{,}27$.

Conexión con RANDU. Como RANDU, el patrón semanal parece aleatorio e independiente si se mira con el lente equivocado. En RANDU basta mirar los valores de uno en uno para que parezcan uniformes, y la estructura aparece al graficar ternas consecutivas en tres dimensiones. En el patrón semanal, mirar solo el retardo 1 oculta casi toda la estructura, que aparece en el retardo 7. En ambos casos, una prueba que mira en la dimensión incorrecta no detecta la dependencia.

0.5 La prueba que sí ve

Proceso	LB $m = 10$	LB $m = 6$	retardo 1
$\phi = 0$ (ruido blanco)	0.0612	0.0600	0.0500
(a) tendencia lineal	1.0000	1.0000	0.9834
(b) patrón semanal	0.9514	0.1948	0.1050

Cuadro 3: Tasa de rechazo al 5 % de Ljung–Box con $m = 10$ y $m = \mathrm{round}(\ln n) = 6$, comparada con la prueba de retardo 1 (5,000 réplicas, $n = 300$). La implementación propia de $Q(10)$ coincide con `acorr_ljungbox` de `statsmodels`: en una serie de (b) ambas dan $Q = 61{,}0555$.

Con ruido blanco, Ljung–Box rechaza el 6.12 % de las réplicas ($m = 10$) y el 6.00 % ($m = 6$), cercano al 5 % esperado (con $n = 300$ la prueba tiene un nivel real ligeramente superior al nominal, además del ruido de simulación de $\pm 0{,}003$). En (a) rechaza siempre, igual que la prueba de retardo 1, por la misma razón: la media no es constante.

El cambio importante está en (b): con $m = 10$ la tasa de rechazo pasa de 10.5 % (retardo 1) a 95.1 %. La prueba de retardo 1 solo mira r_1, que en el patrón semanal es pequeño y negativo, así que no ve el ciclo. $Q(10)$ suma $r_k^2/(n-k)$ para $k = 1, \ldots, 10$ e incluye el retardo 7, donde $\bar{r}_7 = 0{,}2642$. Su aporte a Q es

$$n(n+2)\frac{r_7^2}{n-7} = 300 \cdot 302 \cdot \frac{0{,}2642^2}{293} \approx 21{,}6,$$

que por sí solo supera el valor crítico de una χ^2_{10} al 5 % ($\approx 18{,}3$). Como todos los términos de la suma son no negativos, $Q(10) \geq 21{,}6$ y el rechazo es casi seguro. Elevar r_k al cuadrado evita que las autocorrelaciones positivas y negativas se cancelen.

Con $m = 6$ la tasa de (b) baja a 19.5 %, porque $Q(6)$ ya no incluye el retardo 7: solo acumula los rezagos 1 a 6, que tienen autocorrelaciones pequeñas y negativas inducidas por el patrón. Esto confirma que el rechazo de 95 % con $m = 10$ proviene del retardo 7, y que la elección de m importa: una ventana que no llega al ciclo no lo detecta bien. Por eso se recomienda $m = 2s$ cuando hay estacionalidad de periodo s.

En resumen, la prueba de un solo retardo tiene visión de túnel y solo detecta memoria inmediata. Revisar muchos rezagos por separado contra sus bandas inflaría los falsos positivos por comparaciones múltiples; la prueba portmanteau combina los primeros m rezagos en un solo estadístico con un nivel de significancia global del 5 %, y por eso detecta la estructura semanal que el retardo 1 no ve.

Parte 1: Limpieza

1.1 Carga de datos

Los datos tienen 541,909 filas, 25,900 facturas, 4,070 códigos de producto (`StockCode`) y 4,372 clientes. El 24.93 % de las filas no tiene `CustomerID`.

Las columnas `InvoiceNo`, `StockCode` y `CustomerID` se leen como texto porque son identificadores, no cantidades: `InvoiceNo` incluye prefijos con letras (`C` para cancelaciones y `A` para ajustes contables), `StockCode` mezcla códigos numéricos con letras (`85123A`, `POST`) y `CustomerID`, al tener valores faltantes, se leería como número decimal (`17850.0`) y dejaría de ser un identificador exacto.

1.2 Decisiones de limpieza

Las letras de esta sección describen las decisiones; las letras del Cuadro 4 numeran las reglas en el orden en que se aplicaron. La regla (c) de la bitácora (ventas anuladas por una cancelación manual) se explica en 1.4.

(a) Filas duplicadas exactas: se eliminan. Son 5,268 filas idénticas en factura, producto, cantidad, hora, precio y cliente. Se asume que son registros repetidos y no compras genuinas; conservarlas inflaría la venta (£21,740.98). Es un supuesto, pues no es posible descartar que algún artículo se haya escaneado dos veces de verdad.

(b) Facturas que no empiezan con dígito. Las que empiezan con `C` (9,288 filas) *se quedan*: son cancelaciones y su cantidad negativa ya resta de la venta del día en que ocurren. Las que empiezan con `A` (3 filas) *se eliminan*: corresponden a ajustes contables de deuda incobrable (`Adjust bad debt`), no a ventas de la tienda.

(c) `StockCode` que no son productos: se eliminan. Se eliminan los cargos y ajustes: `POST`, `DOT` y `C2` (envíos), `M` (ajustes manuales), `D` (descuentos), `S` (muestras), `BANK CHARGES`, `AMAZONFEE` y `CRUK` (cargos y comisiones) y `B` (deuda incobrable). Los descuentos son ajustes de precio y las muestras no son ventas, por eso salen. Se *conservan* los códigos que sí corresponden a artículos aunque no empiecen con cinco dígitos: `DCGS*` (productos), `gift_*` (vales de regalo vendidos al cliente) y `PADS`. Se usa una lista explícita de códigos a eliminar y no una regla por patrón, para que cada exclusión quede documentada.

(d) Precios iguales a cero o negativos: se eliminan. Con precio nulo o negativo la línea no genera ingreso en Quantity × UnitPrice. Los dos precios negativos pertenecen a las facturas `A`, ya eliminadas en (b).

(e) Cantidades negativas sin `C`: se eliminan. Son 1,336 filas con descripciones como `damages`, `check` o `thrown away`, y todas tienen precio exactamente 0: son ajustes de inventario, no devoluciones de clientes.

(f) Filas sin `CustomerID`: se conservan. Son compras reales que generaron ingreso y deben estar en la serie de ventas (incluso hay 383 cancelaciones sin cliente, que deben restar). En la Parte 6 sí se excluirán, porque el análisis RFM necesita saber quién compró. Por eso `limpiar` las conserva y el filtro se hace en la Parte 6.

1.3 Bitácora de limpieza

Regla (en orden de aplicación)	Filas eliminadas	Monto (£)
a) duplicados exactos	5,268	21,740.98
b) factura con prefijo `A`	3	−11,062,06
c) venta anulada por cancelación manual (`M`)	17	39,033.26
d) `StockCode` que no es producto	2,902	−34,937,51
e) precio ≤ 0	2,496	0.00
f) cantidad negativa sin `C`	0	0.00
Total eliminado	10,686	14,774.67

Cuadro 4: Bitácora de limpieza: 541,909 filas iniciales y 531,223 finales. El monto es Quantity × UnitPrice de las filas eliminadas por cada regla.

El orden cambia los conteos porque cada regla cuenta solo lo que elimina en ese momento. La regla (f) elimina 0 filas porque todas las cantidades negativas sin `C` tienen precio 0 y la regla (e) las eliminó antes; si (f) se aplicara antes que (e), sería ella la que quitara esas 1,336 filas. De forma similar, las filas `A` usan el `StockCode B`, así que (b) y (d) se solapan y (d) no las vuelve a contar. El monto de (d) es negativo (£−34,937,51) porque esas filas incluyen créditos y ajustes: al eliminarlas, la venta neta total sube.

1.4 Las seis líneas de mayor valor absoluto

Factura	`StockCode`	Cantidad	Fecha y hora	Precio (£)	Monto (£)
581483	23843	80,995	2011-12-09 09:15	2.08	168,469.60
C581484	23843	−80,995	2011-12-09 09:27	2.08	−168,469,60
541431	23166	74,215	2011-01-18 10:01	1.04	77,183.60
C541433	23166	−74,215	2011-01-18 10:17	1.04	−77,183,60
556444	22502	60	2011-06-10 15:28	649.50	38,970.00
C556445	M	−1	2011-06-10 15:31	38,970.00	−38,970,00

Cuadro 5: Las seis líneas con mayor |Quantity × UnitPrice| antes de limpiar.

Son tres pares de compra y cancelación del mismo cliente en cuestión de minutos. En los dos primeros (23843, 12 minutos de diferencia, y 23166, 16 minutos) la limpieza no toca ninguna de las dos líneas y netear por día lo resuelve: ambas caen en la misma fecha y suman cero. El primer par, además, ocurre el 9 de diciembre, el último día del dataset.

El tercer par es distinto. La cancelación `C556445` tiene `StockCode M`, que la regla (d) elimina; con la limpieza inicial quedaba la venta 556444 *sin* su cancelación, y netear por día no puede arreglarlo porque el valor negativo ya no está en los datos: el 10 de junio sumaba £60,907.45, un día inflado frente a la mediana diaria (£27,770.49). Por eso se añadió la regla (c): elimina las ventas con el mismo cliente, día y monto que una cancelación `M` (17 filas, £39,033.26). Con ella el 10 de junio queda en £21,937.45, un día normal.

1.5 La función `limpiar`

Toda la limpieza está en `limpiar(df)` (archivo `src/limpiar.py`), que devuelve el `DataFrame` limpio y, con `devolver_bitacora=True`, la tabla del Cuadro 4. Conserva las filas sin `CustomerID`; la Parte 6 las filtra por su cuenta.

Parte 2: El calendario

2.1 Serie de venta neta diaria

Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 hay 374 días calendario (ambos incluidos), de los cuales 305 tienen al menos una transacción. Quedan 69 días sin transacciones.

2.2 Días sin transacciones

La tienda no abre los sábados: los 53 días sin ventas de ese tipo son todos los sábados del período. Los otros 16 días se clasifican en el Cuadro 6, usando el calendario oficial de *bank holidays* del Reino Unido (gov.uk/bank-holidays).

Fecha	Día	Tipo
2010-12-24	vie	Cierre de fin de año (sin feriado oficial)
2010-12-26	dom	*Boxing Day* (cae en domingo)
2010-12-27	lun	Feriado sustituto de Navidad
2010-12-28	mar	Feriado sustituto de *Boxing Day*
2010-12-29	mié	Cierre de fin de año (sin feriado oficial)
2010-12-30	jue	Cierre de fin de año (sin feriado oficial)
2010-12-31	vie	Cierre de fin de año (sin feriado oficial)
2011-01-02	dom	Domingo dentro del cierre de fin de año
2011-01-03	lun	Feriado sustituto de Año Nuevo
2011-04-22	vie	Viernes Santo (móvil)
2011-04-24	dom	Domingo de Pascua (móvil)
2011-04-25	lun	Lunes de Pascua (móvil)
2011-04-29	vie	Boda real (feriado especial, no recurrente)
2011-05-02	lun	*Early May bank holiday*
2011-05-30	lun	*Spring bank holiday*
2011-08-29	lun	*Summer bank holiday*

Cuadro 6: Días sin transacciones que no son sábados. Los días de cierre de fin de año sin feriado oficial se interpretan como vacaciones de la tienda.

Feriados móviles. Los estrictamente móviles son los de Semana Santa (Viernes Santo, Domingo y Lunes de Pascua): su fecha cambia cada año, y a veces de mes, porque dependen de un cálculo lunar. Son los que FPP2 advierte que son difíciles de modelar con datos diarios. Los *Early May*, *Spring* y *Summer bank holidays* cambian de fecha exacta pero siguen una regla fija (por ejemplo, "el último lunes del mes"), por lo que son predecibles; la boda real fue un evento único y no se repite.

2.3 ¿Cero o dato faltante?

Depende del uso de la serie. Es un **cero** cuando se necesita la estructura del calendario continuo, como en la media móvil de 7 días de la Parte 3: si el día cerrado se omitiera, una ventana de 7 observaciones abarcaría 8 o 9 días reales y distorsionaría el promedio semanal. Es un **dato faltante** cuando se modela la dependencia de las ventas operativas, como en el AR(1) y el SARIMA de la Parte 4: un cero en un día cerrado se leería como un choque negativo extremo de demanda y arruinaría la estimación de la autocorrelación y de la varianza; para el modelo, ese día no existió.

2.4 El último día

El 9 de diciembre de 2011 está incompleto: sus transacciones van de las 08:39 a las 12:50, mientras que la hora de la última transacción de un día normal es típicamente las 17 h (mediana), y su monto (£29,530.26) es menos de la mitad del de los dos días anteriores (£72,571.10 y £76,493.97). Se elimina de la serie, ya que de lo contrario un modelo interpretaría una interrupción en la recolección de datos como una caída real de las ventas.

La serie que se usa de aquí en adelante cubre el calendario completo sin ese último día: 373 días, con los días cerrados marcados como faltantes (69 faltantes y 304 con ventas).

Parte 3: Tendencia, estacionalidad y autocorrelación

3.1 Tendencia

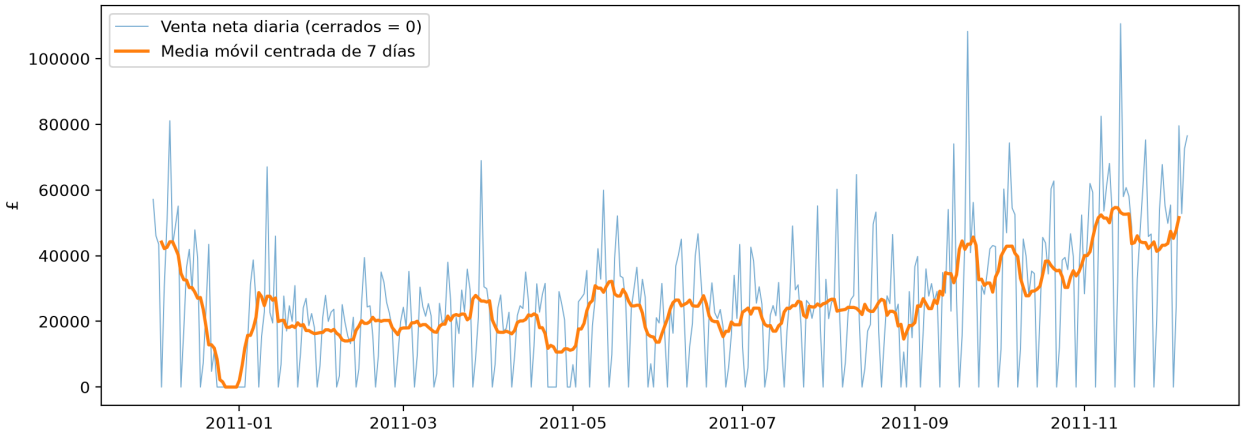


Figura 2: Venta neta diaria (con los días cerrados en cero) y su media móvil centrada de 7 días. La caída casi a cero a finales de diciembre de 2010 corresponde al cierre de fin de año.

Se usa una ventana de 7 días porque la tienda tiene un ciclo semanal (cierra los sábados y su venta cambia según el día): promediar exactamente una semana completa cancela ese ciclo y deja visible la tendencia. Una ventana de 5 días no cubriría el ciclo entero y dejaría parte de la estacionalidad semanal en la curva; una de 30 días suavizaría tanto que ocultaría cambios reales, como la caída de fin de año o el aumento de otoño. La media es *centrada* para que el valor en el día t use los tres días anteriores y los tres posteriores y quede alineado con la fecha; una media que solo mira hacia atrás desplazaría la tendencia unos días hacia el futuro. El costo es que los tres primeros y los tres últimos días quedan sin valor.

La tendencia es casi plana de enero a agosto, con una media móvil entre aproximadamente £15,000 y £25,000 diarios. A partir de septiembre sube con fuerza y supera los £50,000 en noviembre, lo que sugiere una estacionalidad anual de fin de año (que con un solo año de datos no se puede estimar, como se verá en la Parte 5).

3.2 Estacionalidad

El índice estacional de cada día de la semana es el promedio de y_t/MA_t sobre los días abiertos del entrenamiento (hasta el 30 de septiembre de 2011). La media móvil se calculó solo con datos del entrenamiento para que los cocientes de los últimos días no usen información de octubre.

Día	Índice estacional
Lunes	1.1711
Martes	1.5479
Miércoles	1.2273
Jueves	1.5653
Viernes	1.1100
Domingo	0.5767

Cuadro 7: Índice estacional por día de la semana (promedio de y_t/MA_t). El promedio de los seis índices es 1.1997.

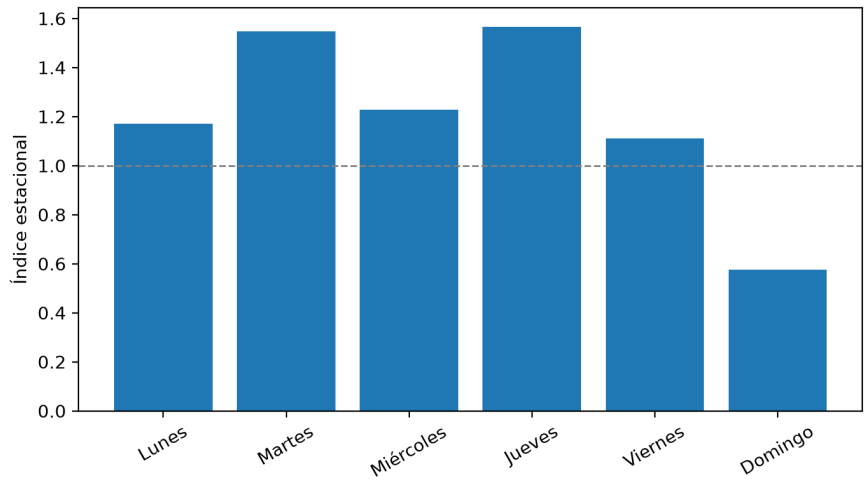


Figura 3: Índice estacional por día de la semana. La línea punteada marca el valor 1.

Venden más los martes (1.55) y los jueves (1.57), y mucho menos los domingos (0.58); lunes, miércoles y viernes quedan intermedios. El promedio de los seis índices no es 1 porque la media móvil divide la venta de la semana entre 7 días, incluido el sábado cerrado con cero, mientras que los cocientes se calculan solo en los 6 días abiertos: si los seis días vendieran lo mismo, cada índice sería $7/6 \approx 1{,}17$. El valor observado (1.1997) es algo mayor porque los feriados dentro de la ventana también bajan la media móvil.

3.3 Autocorrelación

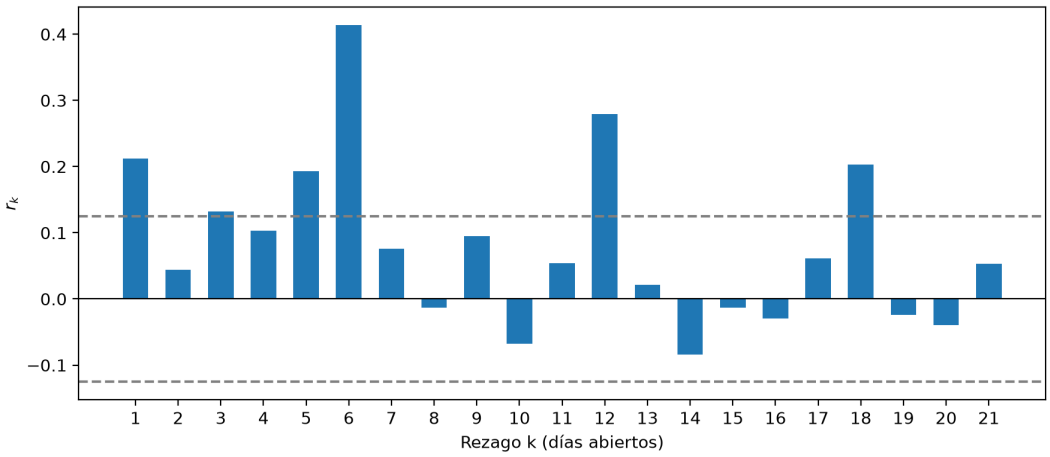


Figura 4: Autocorrelación muestral r_k de la venta de los días abiertos del entrenamiento ($n = 245$), con bandas $\pm 1{,}96/\sqrt{n} = \pm 0{,}1252$. Cada rezago k es un día abierto, no un día calendario.

(a) Seis rezagos se salen de las bandas: 1, 3, 5, 6, 12 y 18. La serie **no pasa** la prueba de retardo 1 de la Tarea 2, pues $r_1 = 0{,}212 > 0{,}1252$. El pico está en $k = 6$ ($r_6 = 0{,}414$); como la tienda abre 6 días por semana, 6 días abiertos equivalen a una semana (unos 7 días calendario). Los rezagos 12 y 18, también altos, son múltiplos de 6 (2 y 3 semanas). Las pruebas de Ljung–Box rechazan con claridad el ruido blanco: $Q(6) = 71{,}53$ ($p = 1{,}98 \times 10^{-13}$) y $Q(12) = 97{,}57$ ($p = 1{,}66 \times 10^{-15}$), valores que coinciden con `acorr_ljungbox` de `statsmodels`.

(b) Según la Parte 0, una serie reprueba por dos razones: memoria y media no constante. Aquí las dos están presentes. El patrón de picos en los múltiplos de 6 es la huella de la media que cambia con el día de la semana (el índice estacional lo confirma), tal como el patrón semanal de la Parte 0.4 producía autocorrelación en el rezago 7 sin memoria alguna. La tendencia, con una media que sube hacia el final del año, también infla r_k en todos los rezagos. No es posible separar cuánto es memoria verdadera mirando solo esta gráfica: eso se hace en la Parte 4, quitando primero la estacionalidad semanal y revisando qué autocorrelación queda en el residuo.

Parte 4: Del AR(1) al SARIMA

4.1 Quitar la estacionalidad semanal

Se ajusta por OLS la venta de los días abiertos del entrenamiento (245 días) contra indicadoras de día de la semana, sin intercepto. Los coeficientes son el promedio de venta de cada día:

Día	Coeficiente (£)
Lunes	27,215.8
Martes	35,170.0
Miércoles	27,838.7
Jueves	35,428.7
Viernes	26,261.6
Domingo	13,716.7

Cuadro 8: Coeficientes del OLS con indicadoras de día.

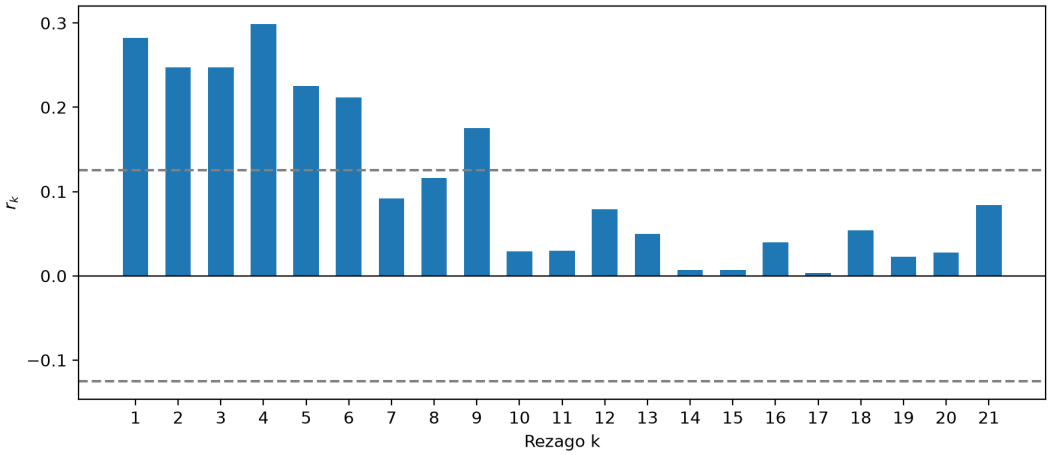


Figura 5: ACF de los residuos e_t del modelo con indicadoras de día, con bandas $\pm 0{,}1252$.

Respecto a la ACF de 3.3, los picos de los rezagos 6, 12 y 18 desaparecieron: el patrón semanal ya está fuera. Pero quedan siete rezagos fuera de las bandas (1 a 6 y 9), todos positivos y similares ($r_1 = 0{,}282$, $r_2 = 0{,}247$, $r_3 = 0{,}248$, $r_4 = 0{,}299$, $r_5 = 0{,}225$, $r_6 = 0{,}212$), y $Q(6) = 96{,}91$, $Q(12) = 112{,}43$ ($p \approx 10^{-18}$): los residuos no son ruido blanco. La forma no es la de un AR(1), que decaería como ϕ^k hasta cero, sino la de una serie que sigue un nivel que cambia lentamente, parecida a la ACF del proceso con tendencia de la Parte 0. Al modelo le falta capturar ese nivel que se mueve (la tendencia que se ve en la media móvil de 3.1: baja en invierno y sube en otoño), porque las indicadoras de día suponen un promedio constante.

4.2 AR(1) sobre los residuos

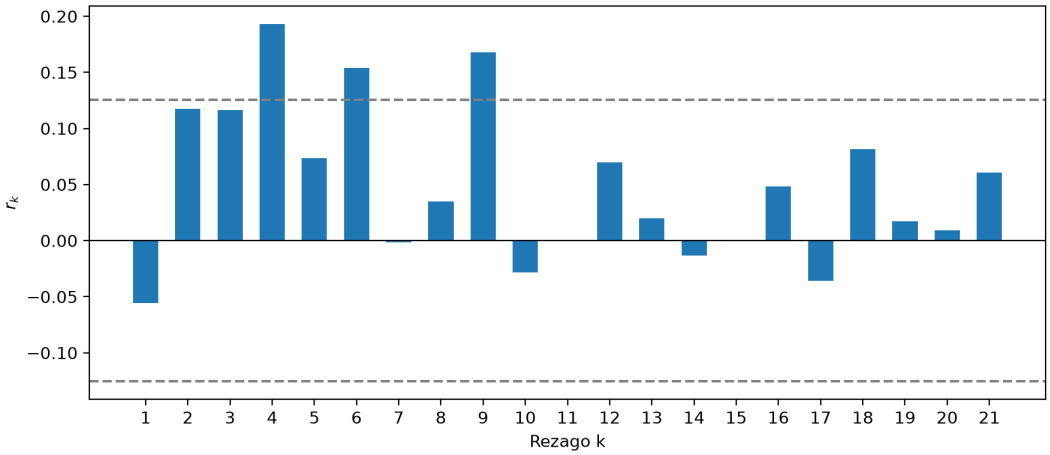


Figura 6: ACF de los residuos u_t del AR(1) ajustado a e_t, con bandas $\pm 0{,}1255$.

El OLS de e_t contra e_{t-1} da $\hat{c} = -100{,}86$ y $\hat{\phi} = 0{,}2843$ (e.e. 0,0611). El AR(1) elimina el rezago 1 ($r_1 = -0{,}055$), pero siguen fuera de las bandas los rezagos 4, 6 y 9, y la prueba de Ljung–Box, con un grado de libertad menos por haber estimado ϕ, rechaza: $Q(6) = 24{,}26$ ($p = 0{,}000194$, 5 g.l.) y $Q(12) = 33{,}23$ ($p = 0{,}000482$, 11 g.l.). Un AR(1) no alcanzó para lo encontrado en 4.1: la autocorrelación que queda viene de un nivel que se mueve lentamente, algo que un AR(1) estacionario con $\hat{\phi} = 0{,}28$ no puede reproducir.

4.3 SARIMA

Se ajustan sobre el logaritmo de la venta diaria de los días abiertos, con estacionalidad $s = 6$:

- S1: SARIMA$(1,0,0)(1,0,0)_6$ con constante.
- S2: SARIMA$(0,1,1)(0,1,1)_6$ sin constante, es decir $(1-B)(1-B^6)\log y_t = (1+\theta B)(1+\Theta B^6)\varepsilon_t$.

Por qué $s = 6$ y no 7. La serie tiene una fila por día abierto y la tienda abre 6 días por semana, así que el mismo día de la semana se repite cada 6 filas (lo confirman los picos de r_k en 6, 12 y 18). Se pasa a `SARIMAX` el arreglo de valores y no la serie con fechas, porque las fechas tienen huecos.

Dónde se rompe esa suposición. Cuando un feriado cae entre semana, la fila siguiente no es el día que correspondería a la semana completa de 6 días abiertos; el ciclo de 6 filas se desfasa. Esto ocurre en Navidad, Semana Santa y los otros feriados de la Parte 2.

Por qué el logaritmo. La estacionalidad es multiplicativa (los índices de 3.2 son cocientes) y la variabilidad crece con el nivel de ventas. El logaritmo convierte los efectos multiplicativos en aditivos y estabiliza la varianza (FPP2, §3.2). Para volver a libras se aplica `exp()` al pronóstico, sin corrección de sesgo.

Convergencia. S1 no convergió con el número de iteraciones por defecto (el indicador de convergencia fue `False`); al subir `maxiter` a 500 sí convergió y los parámetros cambiaron mucho, así como la log-verosimilitud, que mejoró de −187,00 a −162,47:

Parámetro de S1	`maxiter` por defecto	`maxiter`=500
Constante	0.8901	4.2732
$\hat{\phi}$ (AR 1)	0.1387	0.1272
$\hat{\Phi}$ (AR est. 6)	0.8951	0.5165
$\hat{\sigma}^2$	0.2638	0.2189
Log-verosimilitud	−187,00	−162,47

Cuadro 9: Parámetros de S1 antes y después de subir `maxiter`. Se usa la configuración que convergió.

S2 convergió: $\hat{\theta} = -0{,}9092$ (e.e. 0.034), $\hat{\Theta} = -0{,}6836$ (e.e. 0.051) y $\hat{\sigma}^2 = 0{,}2139$.

4.4 Diagnóstico

	$Q(6)$	p	$Q(12)$	p
S1	9.64	0.0469	24.73	0.00589
S2	3.60	0.462	9.26	0.507

Cuadro 10: Ljung–Box sobre los residuos, con $m - 2$ grados de libertad. En S2 se descartan los primeros 7 residuos, que son artefactos del arranque de las diferencias $(1 - B)(1 - B^6)$.

S2 deja residuos de ruido blanco: no se rechaza en ninguno de los dos rezagos ($p = 0{,}46$ y $0{,}51$). S1 no: $Q(6)$ rechaza apenas ($p = 0{,}047$) y $Q(12)$ rechaza con claridad ($p = 0{,}006$), por lo que a S1 le queda autocorrelación sin modelar.

4.5 Hacia dónde van los pronósticos

S1 es estacionario: como en un AR(1) con $|\phi| < 1$, sus pronósticos revierten a la media. A medida que crece el horizonte, el efecto del último dato se desvanece y el pronóstico converge a la media incondicional del logaritmo, $c/((1-\hat{\phi})(1-\hat{\Phi})) \approx 10{,}13$, es decir aproximadamente £25,000 al aplicar `exp()`. Este nivel es coherente con la Parte 3: la media móvil de 3.1 promedia siete días calendario, incluido el sábado cerrado con cero, así que el nivel de un día abierto es unas 7/6 veces mayor (de £15,000–25,000 a £17,500–29,000), y £25,000 cae en ese rango. S1 solo recoge el nivel medio del entrenamiento y pierde el alza reciente de fin de año. S2 no es estacionario: como la caminata aleatoria, no revierte a ninguna media. Su pronóstico conserva el último nivel observado junto con el patrón estacional, y su incertidumbre crece sin cota con el horizonte.

Parte 5: Pronóstico y evaluación

5.1 Modelos y protocolo

Sea y_t la venta neta diaria en libras, definida solo en los días abiertos (los días sin ventas son datos faltantes, no ceros). Los días cerrados (sábados y los feriados de la tabla de la Parte 2) se conocen de antemano, por lo que solo se pronostican días abiertos. Se comparan seis modelos:

- **B1 (media histórica):** $\hat{y}_t = \bar{y}$, el promedio de todos los días abiertos hasta el origen.

- **B2 (ingenuo estacional):** $\hat{y}_t$ es la venta del último día abierto con el mismo día de la semana. Si $t-7$ fue día cerrado, se usa el más reciente anterior (por ejemplo, para el 9 de mayo se usa el 18 de abril, porque el 2 de mayo y el 25 de abril fueron feriados).
- **M1 (OLS):** $y_t = \sum_d \beta_d D_{d,t} + \gamma\, t + \varepsilon_t$, con indicadores de día de la semana (lunes a viernes y domingo) y tendencia lineal en días calendario.
- **M2 (OLS con rezagos):** $y_t = \sum_d \beta_d D_{d,t} + \phi_1 y_{t-7} + \phi_2 y_{t-14} + \varepsilon_t$, con la misma regla de respaldo de B2 para los rezagos. Las filas sin dos rezagos disponibles se descartan al ajustar.
- **S1:** SARIMA$(1,0,0)(1,0,0)_6$ con constante, sobre $\log y_t$.
- **S2:** SARIMA$(0,1,1)(0,1,1)_6$ sin constante, sobre $\log y_t$.

Para S1 y S2 el horizonte h de cada objetivo es su posición entre los días abiertos posteriores al origen, y el pronóstico se transforma con $\exp(\cdot)$ (equivale a la mediana, no a la media). En cada ajuste se verificó `mle_retvals[çonverged"]` con `maxiter=500`. S1 no convergió con el optimizador por defecto en un único origen (4 de septiembre); con el optimizador `bfgs` convergió y el pronóstico casi no cambió, por lo que se usó ese reintento (S1: 31 de 32 ajustes convergieron al primer intento y 32 de 32 tras el reintento; S2: 32 de 32).

Las métricas son MAE y RMSE agrupadas sobre todos los días pronosticados.

Por qué M2 puede usar y_{t-7} pero no y_{t-1}. El origen es un domingo y los objetivos son los siete días siguientes. Para cualquier objetivo t, el día $t-7$ cae a lo sumo en el propio origen, así que y_{t-7} ya se observó. En cambio, y_{t-1} solo se conoce para el lunes (su día anterior es el domingo de origen); para el miércoles, y_{t-1} es el martes, que todavía no ocurrió. S1 sí usa el rezago 1 porque pronostica de forma recursiva: el pronóstico del lunes ocupa el lugar del dato real al pronosticar el martes, y así sucesivamente. Por eso el efecto del último dato observado se desvanece con el horizonte y el pronóstico de S1 revierte a su media (véase 4.5).

5.2 Comparación de esquemas de evaluación

- **(a) Validación cruzada aleatoria** de 5 pliegues sobre el entrenamiento (hasta el 30 de septiembre), repetida con 10 semillas (2026 a 2035), solo para B1, M1 y M2. Se evalúan 233 días (los 12 primeros se excluyen porque M2 necesita dos rezagos del mismo día de la semana). Se reporta el promedio de las 10 repeticiones. La desviación estándar entre semillas es pequeña (MAE: 36 para B1, 74 para M1 y 105 para M2).
- **(b) Origen móvil semanal en el entrenamiento:** 22 orígenes (domingos del 1 de mayo al 25 de septiembre); cada origen ajusta con datos hasta ese domingo y pronostica de lunes a domingo siguientes, sin evaluar días posteriores al 30 de septiembre (128 días evaluados).
- **(c) Origen móvil en la prueba:** 10 orígenes (domingos del 2 de octubre al 4 de diciembre); el último día evaluado es el 8 de diciembre (58 días). El 9 de diciembre se excluye por estar incompleto.

El Cuadro 11 resume los resultados.

	(a) CV aleatoria		(b) Origen móvil, entren.		(c) Origen móvil, prueba	
Modelo	MAE	RMSE	MAE	RMSE	MAE	RMSE
B1	9 551 ± 36	13 534 ± 31	10 228	14 884	22 403	26 927
B2	—	—	11 264	15 570	14 147	18 374
M1	8 226 ± 74	11 336 ± 88	9 761	13 822	15 176	20 148
M2	8 371 ± 105	11 772 ± 118	9 229	13 379	15 156	19 733
S1	—	—	9 720	13 737	16 701	20 933
S2	—	—	10 031	13 959	**12 356**	**15 696**

Cuadro 11: Errores de pronóstico diario (£) por modelo y esquema de evaluación. En (a) se reporta la media ± la desviación estándar entre las 10 semillas.

Por qué (a) no aplica a B2, S1 y S2. B2 no tiene parámetros que estimar, así que un pliegue de validación no mide nada que un ajuste haya aprendido. S1 y S2 son modelos de series de tiempo que necesitan una serie ordenada y continua: al quitar días al azar quedan huecos y el pronóstico deja de ser un pronóstico hacia adelante condicionado al pasado.

Cuál esquema se parece más a (c). El esquema (b), tanto en procedimiento (solo se usan datos pasados y se pronostica hacia adelante) como en magnitud del error. Para M1 el MAE pasa de £8.2k en (a) a £9.8k en (b) y £15.2k en (c). Pero **ninguna de las dos se acerca de verdad** a (c): el error de M1 en (b) (£9.8k) sigue lejos del de (c) (£15.2k), y (b) tampoco ordena igual a los modelos: M2 es el mejor en (b), pero S2 es el mejor en (c), porque en (c) cambió el nivel de las ventas (véase 5.5). Ni (a) ni (b) sirven como estimación confiable del error en la prueba.

5.3 Mejor modelo en la prueba

S2 es el mejor modelo en la prueba, con MAE de £12 356 y RMSE de £15 696, seguido de B2 (£14 147). La Figura 7 muestra los valores reales y los pronósticos de S2, M2 y B2 de octubre a diciembre; las líneas verticales marcan cada origen.

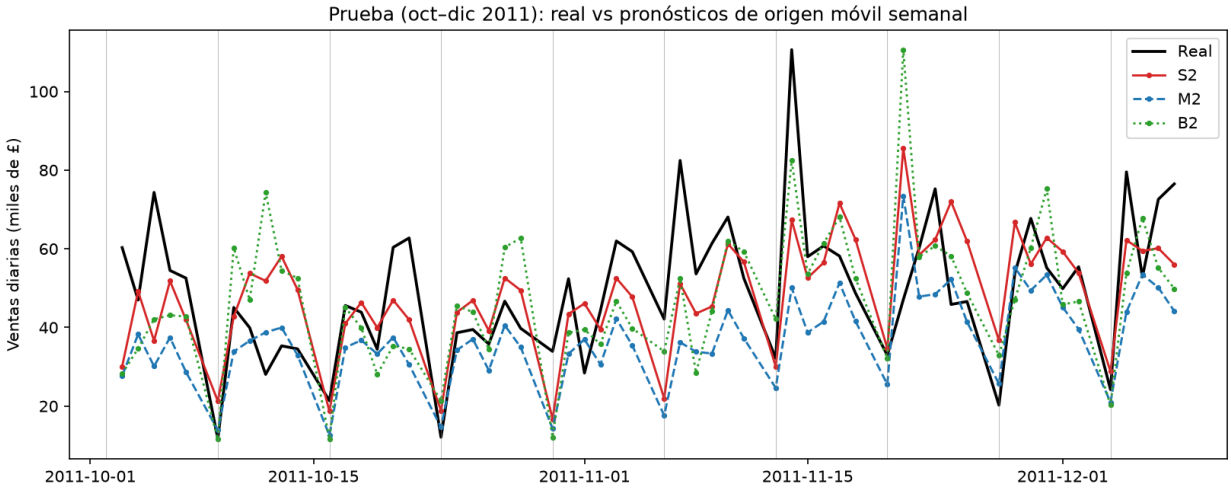


Figura 7: Ventas reales y pronósticos de origen móvil semanal en la prueba (3 de octubre al 8 de diciembre de 2011).

La causa principal es el sesgo. El Cuadro 12 muestra el promedio de (real − pronóstico) en la

prueba: todos los modelos pronostican por debajo de lo real, pero S2 casi no tiene sesgo, porque al diferenciar su nivel se reajusta al último dato. B1, M1, M2 y S1 se anclan a un nivel promedio (S1 revierte a su media histórica, que es el nivel de aproximadamente £25 000 que se observó en la Parte 4) y subestiman sistemáticamente la subida de octubre a diciembre.

	B1	B2	M1	M2	S1	S2
Sesgo (real − pron.), £	20 432	2 736	13 696	12 779	14 235	1 248

Cuadro 12: Sesgo medio en la prueba.

Esto es coherente con la Parte 4, donde S2 tuvo mejores diagnósticos de residuos (Ljung–Box), aunque los residuos limpios por sí solos no garantizan mejor pronóstico: lo que decide en la prueba es que S2 se adapta al nivel.

5.4 La trampa: fuga de información

Se agregó a M2 la media móvil centrada de 7 días, calculada una sola vez sobre toda la serie. Esta variable es **ilegal** como predictor: la media centrada de la fecha t promedia $t-3, \ldots, t+3$, es decir, incluye el propio valor y_t que se quiere predecir y tres días futuros.

El Cuadro 13 compara M2 con y sin la variable.

	(a) CV aleatoria		(b) Origen móvil, entren.	
Modelo	MAE	RMSE	MAE	RMSE
M2	8 371	11 772	9 229	13 379
M2 + media móvil centrada	7 465	10 051	8 253	11 278

Cuadro 13: Efecto de la trampa en (a) y (b).

El error baja cerca de 10 % en ambos esquemas, una mejora aparente que no es real. Que la mejora sea moderada no la hace legítima.

Por qué (b) no lo detecta. El origen móvil solo protege lo que se calcula con datos hasta el origen. Aquí la media móvil se calculó una vez sobre toda la serie, así que para cada día objetivo la columna ya contiene su propio valor y los días posteriores, aunque el modelo "avance" semana a semana.

Por qué (c) no se puede calcular sin trampa. En el origen del 4 de diciembre, la media móvil centrada solo es válida hasta el 1 de diciembre (origen menos 3 días). Para pronosticar el 8 de diciembre habría que conocer las ventas hasta el 11 de diciembre, que todavía no han ocurrido. Los datos de octubre y noviembre sí existen en el archivo, y por eso se podría calcular y hacer trampa, pero un pronóstico real no dispone de esos días.

5.5 Origen del error y limitaciones

Esquema frente a cambio de régimen. Para M1, el paso de £8.2k en (a) a £9.8k en (b) se debe al esquema: la validación aleatoria usa días futuros para predecir días pasados e interpola, lo que subestima el error. El paso de £9.8k a £15.2k en (c) se debe sobre todo al cambio de régimen: las ventas de septiembre (£1.01M) ya superan las de mayo a agosto (cerca de £0.7M al mes), y las de noviembre llegan a £1.43M, por lo que una tendencia lineal ajustada al pasado se queda corta (sesgo de £13 696 en la prueba frente a £5 531 en (b)). Una parte del aumento del error absoluto es solo escala: las ventas medias pasan de £29.7k en (b) a £49.8k en (c), y el error relativo de M1 casi no cambia (33 % en (b) y 31 % en (c)).

Qué arregla una mejor validación y qué no. La causa del esquema (de (a) a (b)) se corrige con un origen móvil que respete el orden del tiempo. La causa del cambio de régimen (de (b) a (c)) no se corrige con ninguna validación interna: un modelo que entrena con meses de ventas moderadas no puede aprender de un pico que todavía no ocurrió. Solo se reduce con más años de historia o con modelos que reajusten su nivel, como S2.

Estacionalidad anual con un año de datos. Con una sola observación por mes, la estacionalidad anual no se puede separar de la tendencia ni del nivel, y los datos empiezan el 1 de diciembre de 2010, por lo que ningún modelo observó un noviembre previo. No se puede saber si el pico de fin de año es un patrón recurrente o un hecho aislado; ningún modelo con un solo año de historia puede anticiparlo.

Parte 6: Detrás de la serie hay clientes (análisis RFM)

6.1 Recencia, frecuencia y monto

Se usan los datos limpios con `CustomerID` y solo las transacciones anteriores al 1 de octubre de 2011. La recencia R es el número de días entre la última factura de venta del cliente y el 1 de octubre; la frecuencia F es el número de facturas de venta distintas (sin las que empiezan con `C`); el monto M es la venta neta total del cliente, que incluye sus cancelaciones.

Hay 3 648 clientes con alguna transacción antes del corte. De ellos, 3 613 tienen al menos una factura de venta y son la base del análisis; los otros 35 solo tienen cancelaciones, y sin compras no hay recencia, así que quedan fuera. Si alguno de ellos compra después del corte, cuenta como cliente nuevo (6.5).

Siete clientes tienen $M \leq 0$ (cuatro con $M = 0$ y tres con $M < 0$, el menor de $-£141{,}50$): compraron algo y después lo devolvieron por completo o más. No se eliminan, porque el enunciado pide incluirlos en el desempate y porque siguen siendo clientes con una compra y una recencia; el M más bajo los lleva al primer quintil de monto.

No se puede usar nada posterior al 1 de octubre porque el indicador de compra de 6.3 se define con ese periodo. Si R, F o M incluyeran compras de octubre a diciembre, quien compró en noviembre tendría una recencia muy pequeña calculada con datos futuros, y el puntaje "predeciría" la compra con información que se obtiene después de ella (fuga de información, como en 5.4). Las variables deben construirse con el pasado conocido en el momento de pronosticar.

6.2 Puntajes por quintiles

Cada dimensión recibe un puntaje de 1 a 5 (en recencia, 5 es el más reciente). Los clientes se ordenan por `CustomerID`, se barajan con `numpy.random.default_rng(2026).permutation` y se aplica `pd.qcut(rank(method='first'), 5)`.

El problema con F. La frecuencia es discreta y muy concentrada: 1 453 clientes (40 %) tienen $F = 1$, más del doble de lo que cabe en un quintil (cerca de 723 clientes, 20 %). Cortar por cuantiles de F directamente falla porque los límites de los grupos se repiten; por eso se ordena por rango y se desempata al azar.

Puntaje	R (días) mín.	R (días) máx.	F (facturas) mín.	F (facturas) máx.	M (£) mín.	M (£) máx.	Clientes
1	177	304	1	1	−141	224	723
2	94	176	1	1	224	412	722
3	41	94	1	3	412	788	723
4	15	41	3	5	789	1 693	722
5	1	15	5	138	1 694	202 084	723

Cuadro 14: Rango de cada variable por puntaje. Los valores $F = 1$, 3 y 5 aparecen en más de un puntaje.

Dos clientes con la misma F pueden caer en puntajes distintos (por ejemplo, con $F = 1$ hay clientes en los puntajes 1, 2 y 3). Esa diferencia no refleja ningún comportamiento: solo depende del orden aleatorio. Por eso el puntaje de F en los niveles bajos es en parte arbitrario, y las diferencias entre puntajes vecinos en ese tramo hay que leerlas con cuidado (véase 6.3).

6.3 ¿Quién compra después?

Se define $\text{compra}_i = 1$ si el cliente tuvo al menos una factura de venta entre el 1 de octubre y el 8 de diciembre. Compraron 1 835 de los 3 613 clientes (50.79 %).

Puntaje	Recencia	Frecuencia	Monto
1	0.278	0.324	0.295
2	0.381	0.313	0.373
3	0.553	0.458	0.458
4	0.665	0.590	0.607
5	0.663	0.855	0.808

Cuadro 15: Fracción de clientes que compró entre el 1 de octubre y el 8 de diciembre, por puntaje.

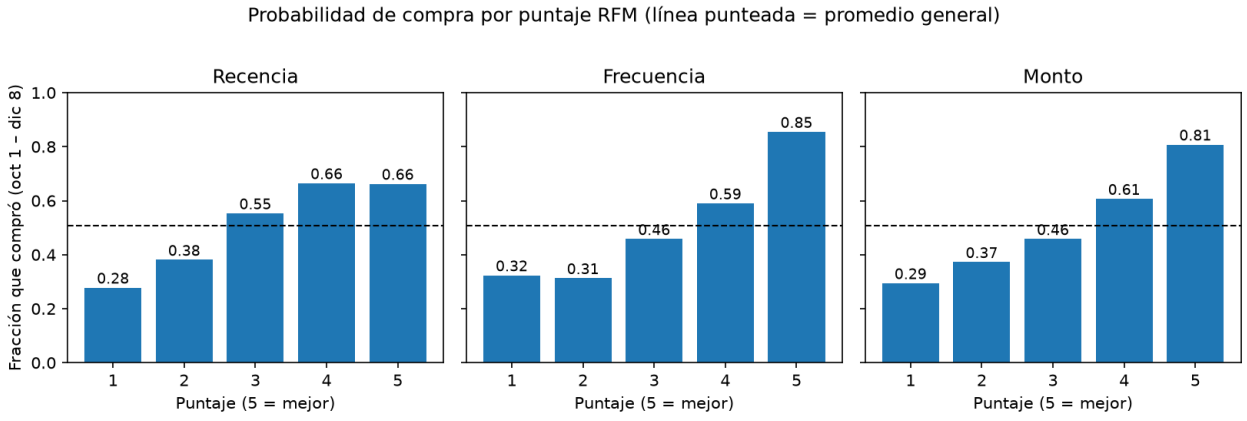


Figura 8: Probabilidad de compra por puntaje de recencia, frecuencia y monto. La línea punteada es el promedio general (50.79 %).

Frecuencia y monto separan mejor que recencia: de 0.32 a 0.85 en F y de 0.29 a 0.81 en M, frente a 0.28 a 0.66 en R. Las irregularidades de las barras no son sistemáticas: el error estándar de

cada fracción es cercano a 0.018, de modo que R en los puntajes 4 y 5 (0.665 y 0.663) y F en los puntajes 1 y 2 (0.324 y 0.313) son prácticamente iguales.

Clasificador	AUC
R (signo invertido)	0.6726
F	0.7205
M	0.7089
Suma de los tres puntajes	0.7342

Cuadro 16: AUC de cada dimensión (valores crudos) y de la suma de puntajes como clasificadores de compra$_i$.

La mejor dimensión es F (AUC 0.7205). La suma de los tres puntajes solo mejora 0.014 (0.7342) porque las dimensiones se solapan: la correlación de Spearman entre F y M es 0.78, y la de R con F y con M es cercana a $-0{,}50$. Quien compra mucho suele gastar más y haber comprado hace poco, así que sumar los puntajes aporta sobre todo información repetida.

6.4 Campeones

Los campeones (puntaje 4 o 5 en las tres dimensiones) son 781 clientes: el 21.62 % de los clientes. Generaron el 53.22 % de la venta neta del 1 de octubre al 8 de diciembre de todos los clientes con `CustomerID` (£2 396 663 en total, incluidos los nuevos). Es decir, una quinta parte de los clientes produjo más de la mitad de la venta.

6.5 Clientes nuevos

Son clientes nuevos los que no tienen ninguna factura de venta antes del 1 de octubre. En la ventana hubo 2 595 clientes con actividad, de los cuales 723 son nuevos, y ellos generaron £378 213, el 15.78 % de la venta neta.

Grupo	Clientes	Fracción de la venta (oct–dic 8)
Campeones	781	53.22 %
Con RFM, no campeones	2 832	31.00 %
Nuevos (sin venta antes del 1 de oct.)	723	15.78 %

Cuadro 17: Reparto de la venta neta del 1 de octubre al 8 de diciembre (£2 396 663) entre los tipos de cliente.

Un análisis RFM, o cualquier modelo construido cliente por cliente, **no puede pronosticar esa venta**: sus variables salen del historial del cliente, y un cliente nuevo no tiene historial. Un pronóstico bottom-up (se pronostica a cada cliente y se suman) solo suma clientes que ya existen, así que subestimaría la venta total en una fracción cercana a la de los nuevos (15.78 % en esta ventana) salvo que se le agregue un modelo aparte de captación. Además, la serie diaria de la Parte 5 incluye ventas sin `CustomerID`, que tampoco ve ningún análisis cliente por cliente.

El pronóstico top-down de la Parte 5 sí "ve" a los clientes nuevos, aunque no los identifique: modela el total, y el total ya contiene el flujo habitual de clientes nuevos. En la prueba, S2 tuvo un sesgo de solo £1 248 (cerca del 2.5 % de la venta media), mientras que ignorar a los nuevos habría dejado fuera cerca del 16 %. Esto vale mientras la captación de clientes se parezca a la pasada. Lo mismo ocurre con las recomendaciones del Proyecto 1 (dónde invertir presupuesto de marketing): parten de hogares ya observados y no dicen cuánto vale atraer hogares que todavía no compran.

Uso de herramientas de IA

Se usó Claude (Anthropic) como asistente a lo largo de toda la tarea, trabajando por partes en una conversación continua. El reparto fue el siguiente.

- **Lo que hizo Claude:** propuso la estructura del repositorio y del notebook; escribió borradores del código de cada parte (simulaciones, `limpiar`, descomposición, SARIMA, origen móvil, RFM); redactó borradores del documento en LaTeX; y revisó las respuestas del autor, señalando errores e imprecisiones. También repitió los cálculos por su cuenta con los mismos datos para comprobar que coincidieran con los del notebook (por ejemplo, la limpieza, de 541,909 a 531,223 filas, y los resultados de las Partes 4, 5 y 6).
- **Lo que hizo el autor:** ejecutó todo el código en su propio notebook y comparó cada resultado, tomó las decisiones de limpieza de la Parte 1 a partir de su exploración de los datos, escribió y corrigió las respuestas de análisis, y revisó el documento final.

Ejemplos de cómo se trabajó.

1. **Parte 0.4(b).** El autor anticipó que el patrón semanal casi no se rechazaría al 5 % y que la autocorrelación sería alta. Claude lo comprobó por simulación (rechazo cercano a 10.5 % y $\bar{r}_7 \approx 0{,}26$) y el autor corrigió su explicación.
2. **Parte 1.4.** Al revisar las seis líneas de mayor valor se vio que eliminar los `StockCode` que no son producto dejaba una venta de £38 970 sin su cancelación (`C556445`); de ahí salió la regla (c) de la bitácora.
3. **Partes 5 y 6.** Claude contrastó las explicaciones del autor con los datos y corrigió afirmaciones: el aumento del error en la prueba no se debía a mayor volatilidad (el error relativo casi no cambia, sino el nivel de ventas), y las tres dimensiones del RFM no están todas altamente correlacionadas (R lo está solo de forma moderada).
4. **Revisión del documento.** Claude compiló el archivo `.tex` y detectó una referencia fija a una tabla con el número equivocado y diferencias de numeración, que se corrigieron.

Los resultados numéricos provienen del notebook del repositorio y fueron revisados por el autor.